

Capítulo 4

Teste de Hipóteses em Modelos Paramétricos

4.1 Introdução

A teoria dos testes de hipóteses se ocupa da avaliação de afirmações gerais sobre a população de interesse com base em dados amostrais. Mais especificamente, dado um modelo paramétrico $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$, então, como antecipado na Seção 1.2, uma **hipótese estatística** é uma afirmação acerca do parâmetro θ ou, equivalentemente, da distribuição que gerou os dados. A afirmação submetida ao teste é denominada **hipótese nula**, denotada por H_0 , e pode ser representada por $H_0 : \theta \in \Theta_0$, em que Θ_0 é um subconjunto próprio de Θ . Assim, H_0 é verdadeira se, e somente se, o valor do parâmetro que caracteriza a população pertence a Θ_0 . A estrutura de uma hipótese é determinada pelo conjunto de valores paramétricos que ela admite. Quando esse conjunto contém um único elemento, como em $H_0 : \theta = \theta_0$, dizemos que H_0 é uma **hipótese simples**; caso contrário, ela é denominada **hipótese composta**. Independentemente do tipo da hipótese, a questão central consiste em avaliar se os dados observados são compatíveis com H_0 ou se fornecem evidência suficiente para colocá-la em dúvida. É importante notar que um teste não estabelece a veracidade de H_0 : ele apenas quantifica, segundo critérios previamente definidos, o grau de discordância entre a hipótese nula e os dados. Para realizar essa avaliação de maneira sistemática, necessitamos de um arcabouço teórico suficientemente rico para a avaliação da hipótese de interesse que permita compreender e quantificar os tipos de incertezas envolvidos nesta avaliação. O objetivo deste capítulo é descrever como isso pode ser feito.

4.1.1 Teste de Significância e p-Valor

Dada a amostra $X_1, \dots, X_n$, suponha uma **estatística teste** $T = T(\mathbf{X})$ tal que, quanto maior a realização $t = T(\mathbf{x})$ de T , maior é a evidência contra H_0 em $\mathbf{x}$. Logo, dado $\mathbf{x}$, é razoável avaliarmos a probabilidade de $T \geq t$ (supondo que o mesmo “experimento” possa ser replicado indefinidamente). Se esta probabilidade for muito baixa para todo $\theta \in \Theta_0$, temos um forte indício contra H_0 . Caso contrário, t é apenas um valor

típico de T sob H_0 . Neste sentido, é razoável tomarmos como medida da “inverossimilhança” da hipótese nula a quantidade

$$p(\mathbf{x}) := \sup_{\theta \in \Theta_0} P_\theta(T \geq T(\mathbf{x})), \quad (4.1)$$

denominada **p-valor** (ou **valor de P**). Em especial, no caso da hipótese simples $H_0 : \theta = \theta_0$, a expressão acima se reduz a

$$p(\mathbf{x}) = P_{\theta_0}(T \geq T(\mathbf{x})). \quad (4.2)$$

Quando o p-valor é “substancialmente pequeno”, dizemos que o possível desvio de H_0 é **significante**. A proposição a seguir reforça o caráter do p-valor como potencial evidência estatística contra H_0 .

PROPOSIÇÃO 4.1.1. *Se $\mathbf{X} \sim P_\theta$, então, para todo $0 < \alpha < 1$,*

$$\sup_{\theta \in \Theta_0} P_\theta(p(\mathbf{X}) \leq \alpha) \leq \alpha. \quad (4.3)$$

Prova. Tomando $\theta \in \Theta_0$ e $\mathbf{X} \sim P_\theta$,

$$p_\theta(\mathbf{x}) := P_\theta(T \geq T(\mathbf{x})) = P_\theta(V \leq -T(\mathbf{x})) := F_{V,\theta}(-T(\mathbf{x})),$$

em que $V = -T$. Logo, $p_\theta(\mathbf{X}) = F_{V,\theta}(V)$ e, portanto,

$$P_\theta(p_\theta(\mathbf{X}) \leq \alpha) = P_\theta(F_{V,\theta}(V) \leq \alpha).$$

Escrevendo $F_{V,\theta}^-(\alpha) = \sup\{v : F_{V,\theta}(v) \leq \alpha\}$ (Figura 4.1), obtemos




Figura 4.1: Quantil generalizado $F_{V,\theta}^-(\alpha)$ de ordem α .

$$P_\theta(p_\theta(\mathbf{X}) \leq \alpha) \leq P_\theta(V < F_{V,\theta}^-(\alpha)) = \lim_{h \downarrow 0} P_\theta(V < F_{V,\theta}^-(\alpha) - h) \leq \alpha, \quad (4.4)$$

de modo que

$$P_\theta(p(\mathbf{X}) \leq \alpha) = P_\theta\left(\sup_{\theta' \in \Theta_0} p_{\theta'}(\mathbf{X}) \leq \alpha\right) \leq P_\theta(p_\theta(\mathbf{X}) \leq \alpha) \leq \alpha.$$

Note que a primeira desigualdade só é possível porque $\theta \in \Theta_0$. □

OBSERVAÇÃO 4.1.1.

1. Se T é absolutamente contínua, então $F_{V,\theta}^- = F_{V,\theta}^{-1}$ e, portanto, $P_\theta(p_\theta(\mathbf{X}) \leq \alpha) = \alpha$ em (4.4). Além disso, se $H_0 : \theta = \theta_0$, então

$$P_{\theta_0}(p(\mathbf{X}) \leq \alpha) = P_{\theta_0}(p_{\theta_0}(\mathbf{X}) \leq \alpha) = \alpha.$$

2. De modo um pouco mais genérico, qualquer estatística $p(\mathbf{X})$ satisfazendo (4.3) é chamada de *p-valor válido*.

Exemplo 4.1.1. Sejam $X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \mathcal{N}(\theta, \sigma^2)$, com σ^2 conhecida, e suponha $H_0 : \theta = \theta_0$. Tomando como base a estatística teste

$$T = \left| \frac{\bar{X} - \theta_0}{\sigma/\sqrt{n}} \right| \quad (4.5)$$

e supondo dada a observação $\mathbf{x}$, o p-valor correspondente é

$$p(\mathbf{x}) = P_{\theta_0} \left(T \geq \left| \frac{\bar{x} - \theta_0}{\sigma/\sqrt{n}} \right| \right) = 2 \left[1 - \Phi \left(\left| \frac{\bar{x} - \theta_0}{\sigma/\sqrt{n}} \right| \right) \right]. \quad (4.6)$$

As formas do p-valor em (4.6) como função da média observada $\bar{x}$ para $n = 100$ e $n = 500$, assumindo $\theta_0 = 0$ e $\sigma^2 = 1$, são apresentadas na Figura 4.2. Observe como as funções tendem a se concentrar cada




Figura 4.2: p-valor (4.6) calculado em função de $\bar{x}$ para $n = 100$ e $n = 500$ com $\theta_0 = 0$ e $\sigma^2 = 1$.

vez mais em torno de θ_0 conforme aumentamos o tamanho amostral. Isso indica que o p-valor tende a capturar qualquer discrepância da hipótese nula, por menor que ela seja, desde que o tamanho amostral seja suficientemente grande. Adicionalmente, a Figura 4.3 ilustra a Proposição 4.1.1 aplicada a este caso e o fato de que, fora de Θ_0 , (4.3) não se aplica. Se H_0 não vale, então (como desejado) a distribuição de $p(\mathbf{X})$ tende a se concentrar na vizinhança de zero e o faz de forma cada vez mais acentuada conforme aumentamos o tamanho amostral.




Figura 4.3: Histogramas de $p(\mathbf{X})$ calculados sob a hipótese $H_0 : \theta = 0$ a partir de 10.000 amostras de diferentes tamanhos extraídas de uma população $\mathcal{N}(\theta_0, 1)$, com $\theta_0 = 0$ e $\theta_0 = 0, 15$.

O cálculo do p-valor para hipóteses compostas pode ser particularmente difícil, pois devemos, em princípio, avaliar a hipótese nula em cada elemento de Θ_0 para obter o supremo em (4.1). Porém, o cálculo do p-valor quando pode ser bastante simplificado se a distribuição da estatística teste é invariante em Θ_0 . Isto é, se a sua distribuição segue inalterada quando variamos $\theta \in \Theta_0$. Nestes casos, a fórmula do p-valor também é dada por (4.2), porém com θ_0 podendo ser qualquer elemento de Θ_0 .

Exemplo 4.1.2. *Afirma-se que um tratamento possui um efeito médio de τ sobre o desfecho Y relativamente ao grupo não tratado (controle). Para avaliar esta afirmação, indivíduos são alocados aleatoriamente a um desses dois grupos segundo a variável binária A de modo que $A = 1$, se o indivíduo for tratado, e $A = 0$, caso contrário. Supondo $Y|A = a \sim \mathcal{N}(\mu_a, \sigma^2)$, com σ^2 conhecida, queremos testar $H_0 : \delta \equiv \mu_1 - \mu_0 = 0$ com base na amostra aleatória $\{(A_i, Y_i) : i = 1, \dots, n\}$. Antes, no entanto, observe que o modelo é indexado por $\theta = (\mu_0, \mu_1, p) \in \mathbb{R}^2 \times (0, 1)$ em que $p = P(A = 1)$. Logo, a hipótese nula é composta, pois $\Theta_0 = \{(\mu_0, \mu_1, \sigma^2) : \mu_0 = \mu_1, \sigma^2 > 0\}$. Além disso,*

$$E_\theta Y = E_\theta(Y | A = 0) P_\theta(A = 0) + E_\theta(Y | A = 1) P_\theta(A = 1) = \mu_0(1 - p) + \mu_1 p,$$

e

$$\text{Var}_\theta Y = \text{Var}_\theta E_\theta(Y | A) + E_\theta \text{Var}_\theta(Y | A) = (\mu_1 - \mu_0)^2 p(1 - p) + \sigma^2,$$

de modo que, sob H_0 , $E_\theta Y = \mu_0$ e $\text{Var}_\theta Y = \sigma^2$, implicando $Y \sim \mathcal{N}(\mu_0, \sigma^2)$. Por outro lado, defina $\bar{Y}_a = n_a^{-1} \sum_{i: A_i = a} Y_i$, em que $n_a = \sum_{i=1}^n \mathbb{1}(A_i = a)$ representa a quantidade de unidades amostrais no grupo a . Então, sob H_0 ,

$$\text{Var}_0 (\bar{Y}_1 - \bar{Y}_0) = \text{Var}_0 \bar{Y}_1 + \text{Var}_0 \bar{Y}_0 = \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_0} = \frac{\sigma^2}{M},$$

com $M = n_1 n_0 / (n_0 + n_1)$ e $\bar{Y}_1 - \bar{Y}_0 \sim \mathcal{N}(0, \sigma^2 / M)$ sob H_0 . Tomando a estatística teste

$$T = \left| \frac{\bar{Y}_1 - \bar{Y}_0}{\sigma / \sqrt{M}} \right|,$$

temos o p-valor

$$p(\mathbf{y}) = P_0 \left(T \geq \left| \frac{d}{\sigma/\sqrt{M}} \right| \right) = 2 \left[1 - \Phi \left(\left| \frac{d}{\sigma/\sqrt{M}} \right| \right) \right], \quad (4.7)$$

em que $\mathbf{y} = (y_{01}, \dots, y_{0n_0}, y_{11}, \dots, y_{1n_1})$ e $d = \bar{y}_1 - \bar{y}_0$.

Outra característica dos p-valores é a sua invariância relativamente a transformações crescentes da estatística teste: se g é uma função crescente, então os p-valores associados a T e a $W = g(T)$ coincidem. De fato, denotando por p_T e p_W os seus respectivos p-valores e usando o fato de que g é monótona crescente (de modo que $g(T) \geq g(T(\mathbf{x})) \Leftrightarrow T \geq T(\mathbf{x})$), temos

$$\begin{aligned} p_W(\mathbf{x}) &= \sup_{\theta \in \Theta_0} P_\theta(W \geq W(\mathbf{x})) \\ &= \sup_{\theta \in \Theta_0} P_\theta(g(T) \geq g(T(\mathbf{x}))) \\ &= \sup_{\theta \in \Theta_0} P_\theta(T \geq T(\mathbf{x})) \\ &= p_T(\mathbf{x}), \end{aligned}$$

para todo $\mathbf{x} \in \mathcal{X}_n$. Por outro lado, é importante ressaltar que estatísticas testes distintas não necessariamente resultam nos mesmos p-valores.

Exemplo 4.1.1 (Continuação). Defina $S = \sum_{i=1}^n \mathbb{1}(X_i - \theta_0 > 0)$ e note que $P_{\theta_0}(X_i - \theta_0 > 0) = 1/2$ ou, equivalentemente, $E_{\theta_0} \mathbb{1}(X_i - \theta_0 > 0) = 1/2$. Além disso, como a amostra é aleatória, $S \sim \text{Binomial}(n, 1/2)$ sob H_0 . A estatística S também caracteriza o Teste do Sinal na teoria de testes de hipóteses não-paramétricos. Neste momento, porém, desejamos apenas observar que o p-valor associado a S difere do p-valor associado a T em (4.6):

$$p_S(\mathbf{x}) = P(S \geq S(\mathbf{x})) = \frac{1}{2^n} \sum_{s \geq S(\mathbf{x})} \binom{n}{s} \neq p(\mathbf{x}).$$

Agora, se p-valores associados a diferentes estatísticas testes não são necessariamente iguais, eles também devem resultar nas mesmas inferências. Sendo assim, devemos nos perguntar: dada uma coleção de estatísticas testes competidoras, qual delas é (se houver) a mais recomendável? Poderíamos escolher aquela cujo p-valor mais rapidamente se concentra em torno de zero (no sentido da Figura 4.3). Porém, este caminho não parece ser o adequado. Basta dizer, por exemplo, que esta comparação vale apenas para $n \rightarrow \infty$ e pouco diz quando o tamanho amostral é um valor fixado.

Merece ainda atenção o fato de que p-valores são construídos à revelia dos possíveis desvios da hipótese nula e desconsideram a relevância desses desvios no seguinte sentido: mesmo que o desvio relativo à hipótese nula seja absolutamente irrelevante em termos práticos, se H_0 é falsa, então quaisquer p-valores válidos tendem a ser próximos de zero para n suficientemente grande. Ou seja, um p-valor pequeno indica uma não conformidade dos dados com a hipótese nula, mas nada diz sobre a relevância do efeito (ou desvio de H_0).

Exemplo 4.1.2 (Continuação). A Figura 4.4 ilustra o p -valor (4.7) quando H_0 é falsa e verdadeira sob diferentes tamanhos amostrais ($n = 500$ e $n = 5.000$). Para H_0 verdadeira (i.e., $\delta = 0$), os p -valores




Figura 4.4: Histogramas de $p(\mathbf{Y})$ calculado sob $H_0 : \delta = 0$ com efeitos (reais) $\delta = 0$ e $\delta = 0,05$ a partir de 5.000 amostras de diferentes tamanhos.

associados a $n = 500$ e $n = 5.000$ têm comportamentos semelhantes e em conformidade com a Proposição 4.1.1. Por outro lado, quando $\delta = 0,05$, ao passar de $n = 500$ para $n = 5.000$, observamos que o p -valor tende a se concentrar em torno do zero indicando (corretamente!) que as observações não ratificam H_0 . Sob uma perspectiva prática, no entanto, notamos que o efeito $\delta = 0,05$ é substancialmente inferior ao desvio-padrão populacional de 1, o que sugere um efeito potencialmente desprezível (i.e., para todos os efeitos práticos, essencialmente igual a $\delta = 0$) e que não deveria ser considerado significativo. Em contraste, quando $n = 500$, notamos que o comportamento do p -valor nos casos em que $\delta = 0$ e $\delta = 0,05$ não são tão díspares. Então, ficamos assim: se o efeito é desprezível, preferimos o p -valor associado a tamanhos amostrais menores (maior variabilidade, menos precisão), mas se o efeito não é desprezível, preferimos o p -valor associado a tamanhos amostrais maiores (menor variabilidade, maior precisão).

Os pontos acima apontam para algumas limitações dos p -valores. Em primeiro lugar, não fica claro como escolher um teste entre vários como o mais apropriado a um determinado problema e, em segundo lugar, o p -valor ignora quaisquer postulações distintas de H_0 e, conseqüentemente, é incapaz de contrastar essas postulações alternativas com a hipótese nula. Em termos práticos, isso significa fazer inferências

sobre o mundo sem sequer conjecturar como o mundo (isto é, as observações) deveriam se comportar se essas conjecturas forem verdadeiras (o que é sempre uma possibilidade!).

Historicamente, testes de significância foram empregados muito antes de sua formalização, no início do século XX. Segundo [Gorroochurn \(2016\)](#), a primeira publicação a apresentar um argumento desse tipo foi o artigo de 1710 do médico John Arbuthnot, intitulado “*An Argument for Divine Providence, taken from the constant Regularity observed in the Births of both Sexes*”. Nele, Arbuthnot procura demonstrar que a distribuição dos nascimentos entre os sexos masculino e feminino não seria obra do acaso, atribuindo a regularidade observada à providência divina. Seu argumento parte do fato de que, durante 82 anos consecutivos, o número de meninos nascidos foi superior ao de meninas. Denotando por X o número de anos em que isso ocorre e supondo independência entre os anos e probabilidade $1/2$ de predominância de cada sexo, tem-se, sob H_0 , $X \sim \text{Bernoulli}(82; 1/2)$. Como $P_0(X = 82) \approx 2,07 \times 10^{-25}$ o resultado fornece evidência consideravelmente forte contra H_0 , constituindo, em linguagem moderna, um p-valor. Embora esse seja possivelmente o primeiro uso documentado de um raciocínio dessa natureza, a introdução do p-valor como instrumento estatístico de teste costuma ser associada ao artigo de Pearson, “*On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling*” ([Pearson, 1900](#)), no qual foi apresentado o teste qui-quadrado de bondade de ajuste. A ampla difusão dos testes de significância, já sob essa denominação, deve-se sobretudo a R. A. Fisher e, em particular, ao livro “*Statistical Methods for Research Workers*” ([Fisher, 1950](#)). Com base na aproximação normal da média amostral para amostras suficientemente grandes, Fisher propôs, como regra prática, considerar significantes os desvios superiores a aproximadamente dois erros-padrão. Se $T \sim \mathcal{N}(0, 1)$, a probabilidade de observar $|T| \geq 2$ é aproximadamente 5%; ou, mais precisamente, o limiar para atribuição de significância seria $z_{0,975} \approx 1,96$. O quantil de ordem 5% como limiar para significância se popularizou sendo adotado para outras estatísticas de teste (não necessariamente distribuídas conforme a distribuição Normal padrão) e permanece amplamente utilizada. Sua aplicação indiscriminada é particularmente problemática em hipóteses simples, pois, diferenças de magnitude desprezível podem produzir p-valores arbitrariamente pequenos à medida em que o tamanho amostral aumenta. Convém ressaltar, contudo, que Fisher não formulava o procedimento em termos de “rejeitar” H_0 ; seu objetivo era estabelecer um critério prático para avaliar se os dados continham evidência suficiente contra a hipótese nula para justificar que se duvidasse dela. A expressão *p-valor* surgiria apenas posteriormente: Fisher empregava simplesmente a notação P , e o termo teria sido introduzido por W. E. Deming, em 1943, no livro “*Statistical Adjustment of Data*” ([Gorroochurn, 2016](#)).

4.1.2 A Abordagem de Neyman-Pearson

Testes e a Função Poder

Chamamos de *teste* qualquer função mensurável $\phi : \mathcal{X}_n \rightarrow [0, 1]$. Mais precisamente, se ϕ assume valores estritamente entre 0 e 1, então o teste é denominado *aleatorizado* e interpretado da seguinte forma: dado x e um mecanismo externo de aleatorização (e.g., o lançamento de uma moeda viciada cuja probabi-