

4.3 A Abordagem de Neyman-Pearson

4.3.1 Testes Estatísticos e a Função Poder

Chamamos de **teste** qualquer função mensurável $\phi : \mathcal{X}_n \rightarrow [0, 1]$. Mais precisamente, se ϕ assume valores estritamente entre 0 e 1, então o teste é denominado **aleatorizado** e interpretado da seguinte forma: dado $\mathbf{x}$ e um mecanismo externo de aleatorização (e.g., o lançamento de uma moeda viciada cuja probabilidade de ‘Cara’ é $\phi(\mathbf{x})$), H_0 é rejeitada com probabilidade $\phi(\mathbf{x})$. Note, porém, que $\phi(\mathbf{x})$ **não** representa a probabilidade de H_0 ser falsa! Testes aleatorizados são raramente usados na prática, mas possuem grande importância no desenvolvimento da teoria testes de hipóteses. Na prática, os testes são construídos de forma que ϕ assume apenas os valores 0 e 1. Neste caso, o teste é denominado **não aleatorizado**, e **rejeitamos** H_0 se, e somente se, $\phi(\mathbf{x}) = 1$. Convém observar que os verbos ‘rejeitar’ e ‘aceitar’ devem ser devidamente interpretados, pois nenhuma decisão é livre de erro. Logo, a rejeição ou aceitação de H_0 são decisões puramente operacionais, pois não implicam de modo algum a falsidade ou veracidade de H_0 .

A negação de H_0 determina uma **hipótese alternativa** sobre θ denotada por H_1 . A hipótese alternativa é caracterizada pelo subconjunto $\Theta_1 = \Theta \setminus \Theta_0$ e escrevemos $H_1 : \theta \in \Theta_1$. Desse modo, Θ_0 e Θ_1 formam uma partição do espaço paramétrico,

$$\Theta_0 \cap \Theta_1 = \emptyset \quad \text{e} \quad \Theta_0 \cup \Theta_1 = \Theta.$$

Como consequência, a veracidade de H_0 implica a falsidade de H_1 , e vice-versa. Se as hipóteses são da forma $H_0 : \theta \leq \theta_0$ vs. $H_1 : \theta > \theta_0$, dizemos tratar-se de um **teste unilateral**. Obviamente, encontram-se nesta categoria todas as variações análogas que podemos obter trocando as desigualdades. Por outro lado, as hipóteses são da forma $H_0 : \theta = \theta_0$ vs. $H_1 : \theta \neq \theta_0$, temos um **teste bilateral**. Nesta categoria, também se incluem testes de hipóteses com $H_0 : \theta_* \leq \theta \leq \theta^*$ vs. $H_1 : \theta < \theta_*$ ou $\theta > \theta^*$, bem como suas variações obtidas pela modificação das desigualdades. Em todos esses casos, a especificação conjunta das hipóteses nula e alternativa fornece uma descrição completa do espaço paramétrico Θ . Esse aspecto caracteriza o teste de hipóteses como um problema de decisão em oposição à abordagem fisheriana dos testes de significância, na qual se especifica unicamente H_0 e se avalia a potencial incompatibilidade dos dados com H_0 , sem a necessidade de se explicitar uma hipótese alternativa.

Bons testes devem rejeitar a hipótese nula com alta probabilidade sob H_1 ($\theta \in \Theta_1$) e, reciprocamente, rejeitar a hipótese nula com baixa probabilidade sob H_0 ($\theta \in \Theta_0$). Neste sentido, a **função poder**

$$\begin{aligned} \Pi : \Theta &\rightarrow [0, 1] \\ \theta &\mapsto E_\theta \phi(\mathbf{X}), \end{aligned}$$

exerce um papel central na teoria de teste de hipóteses. De fato, se $d : \mathcal{X}_n \rightarrow \{0, 1\}$ representa a regra de decisão tal que $d(\mathbf{x}) = 1$ significa ‘rejeitar’ H_0 e $d(\mathbf{x}) = 0$, ‘aceitar’ H_0 , então, para todo $\theta \in \Theta$,

$$P(\text{“Rejeitar } H_0\text{”}) = P_\theta(d(\mathbf{X}) = 1) = E_\theta P_\theta(d(\mathbf{X}) = 1 | \mathbf{X}) = E_\theta \phi(\mathbf{X}) = \Pi(\theta).$$

Logo, um bom teste deve ter $\Pi|_{\Theta_0}$ próximo de zero e $\Pi|_{\Theta_1}$ próximo de um.

No caso particular dos testes não-aleatorizados, $\Pi(\theta) = P_\theta(\phi(\mathbf{X}) = 1)$. Alternativamente, como podemos apenas rejeitar ou aceitar H_0 em testes não-aleatorizados, faz sentido considerar o conjunto

$$\mathcal{R} = \{\mathbf{x} \in \mathcal{X}_n : \phi(\mathbf{x}) = 1\},$$

chamado **região crítica** ou **região de rejeição**. Consequentemente, a hipótese nula é rejeitada se, e somente se, $\mathbf{x} \in \mathcal{R}$ e, portanto, a função poder pode ser escrita na forma $\Pi(\theta) = P_\theta(\mathbf{X} \in \mathcal{R})$. Além disso, dada uma estatística de teste T , podemos sempre construir o teste não-aleatorizado $\phi(\mathbf{x}) = \mathbb{1}\{T(\mathbf{x}) > \kappa\}$, para algum $\kappa \in \mathbb{R}$. Neste caso, a região crítica assume a forma

$$\mathcal{R} = \{\mathbf{x} \in \mathcal{X}_n : T(\mathbf{x}) > \kappa\},$$

com κ recebendo o nome de **valor crítico**, e, consequentemente, $\Pi(\theta) = P_\theta(T > \kappa)$.

Exemplo 4.2.1 (Continuação). Usando (4.5) e tomando $\phi = \mathbb{1}(T > \kappa)$, com $\kappa > 0$, temos

$$\Pi(\theta) = P_\theta(T > \kappa) = 2 - \Phi\left(\kappa - \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right) - \Phi\left(\kappa + \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right). \quad (4.8)$$

Em particular, se $\theta = \theta_0$,

$$\Pi(\theta_0) = 2(1 - \Phi(\kappa)).$$

Diferentes valores de κ implicam testes distintos como indicado na Figura 4.5. Quanto menor for o




Figura 4.5: Função poder (4.8) com $\theta_0 = 0$ e diferentes tamanhos amostrais.

valor de κ , maior será a probabilidade de rejeitar H_0 (mesmo que H_0 seja verdadeira). Do mesmo modo, quanto maior for o valor de κ , menor será a probabilidade de rejeitar H_0 (mesmo que H_0 seja falsa). Essa ambiguidade reflete um fenômeno geral nos testes de hipóteses, ferindo o desiderato descrito acima de termos $\Pi|_{\Theta_0}$ próximo de zero e $\Pi|_{\Theta_1}$ próximo de um. No caso específico deste exemplo, isso sugere que devemos escolher um valor “intermediário” para κ . Por fim, observamos que o tamanho amostral também possui um papel importante na função poder: quanto maior n , maior é a probabilidade de rejeição em Θ_1 . Porém, em Θ_0 , a probabilidade de rejeição permanece inalterada, pois o fator $\sqrt{n}(\theta - \theta_0)/\sigma$ é nulo em $\theta = \theta_0$.

4.3.2 Testes Não-Viciados

Dado um teste qualquer, é razoável esperar dele que a probabilidade de rejeição em Θ_0 seja **sempre menor ou igual** à probabilidade de rejeição em Θ_1 . Neste sentido, dizemos que o teste é **não-viciado** se

$$\sup_{\theta \in \Theta_0} \Pi(\theta) \leq \inf_{\theta \in \Theta_1} \Pi(\theta). \quad (4.9)$$

Em particular, se o teste possui tamanho α , então ele é não-viciado se $\Pi(\theta) \geq \alpha$, para todo $\theta \in \Theta_1$.

Exemplo 4.3.1. Suponha $X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \mathcal{N}(\theta, \sigma^2)$, com σ^2 conhecida. Para testar as hipóteses $H_0 : \theta \leq \theta_0$ vs. $H_1 : \theta > \theta_0$, considere as seguintes três estatísticas,

- (1) $T_1 = \sqrt{n}(\bar{X} - \theta_0)/\sigma$;
- (2) $T_2 = \sqrt{n}|\bar{X} - \theta_0|/\sigma$;
- (3) $T_3 = -\sqrt{n}(\bar{X} - \theta_0)/\sigma$.

Supondo em todos os casos uma região crítica da forma $[T_j > \kappa_j]$, as suas respectivas funções poder são dadas por

$$\begin{aligned} \Pi_1(\theta) &= 1 - \Phi\left(\kappa_1 - \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right); \\ \Pi_2(\theta) &= 1 - \Phi\left(\kappa_2 - \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right) + \Phi\left(-\kappa_2 - \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right); \\ \Pi_3(\theta) &= \Phi\left(-\kappa_3 - \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right). \end{aligned}$$

No primeiro caso, a função poder é estritamente crescente, de modo que $\Pi_1(\theta') > \Pi_1(\theta'')$, para todos $\theta'' \leq \theta_0 < \theta'$. Logo, o teste correspondente é não-viciado. Porém, nos demais casos,

$$\lim_{\theta \rightarrow -\infty} \Pi_2(\theta) = \lim_{\theta \rightarrow -\infty} \Pi_3(\theta) = 1,$$

e os testes são forçosamente viciados. A figura 4.6 ilustra as respectivas funções poder quando $\theta_0 = 0$, $\sigma = 1$ e $n = 100$. Note que a curva azul, associada a T_1 , é a única que satisfaz (4.9), pois está associada ao único teste não-viciado entre os três candidatos. Observe ainda que a presença ou ausência de viés é sempre relativa às hipóteses testadas. Por exemplo, para as hipóteses $H_0 : \theta \geq 0$ vs. $H_1 : \theta < 0$, o teste associado a T_3 (curva verde) seria o único não-viciado dentre os testes considerados. Analogamente, no caso do teste bilateral $H_0 : \theta = 0$ vs. $H_1 : \theta \neq 0$, seria o teste associado a T_2 (curva vermelha) o único não-viciado.




Figura 4.6: Funções poder associados às estatísticas T_1 , T_2 e T_3 para testar $H_0 : \theta \leq 0$ vs. $H_1 : \theta > 0$ quando $\sigma = 1$ e $n = 100$. Os valores de κ foram escolhidos de modo que $\Pi_j(0) = 5\%$.

4.3.3 Erros Tipo I e II, Tamanho do Teste e Nível de Significância

A abordagem de Neyman-Pearson consiste, no final das contas, em buscar, dentro de uma família de candidatos, o teste com menor probabilidade de rejeição sob H_0 e maior probabilidade de rejeição sob H_1 . Quando nos decidimos por uma dessas hipóteses em detrimento da outra, estamos evidentemente sujeitos a um dos erros,

Erro tipo I: rejeitar H_0 , quando ela é verdadeira;

Erro tipo II: aceitar H_0 , quando ela é falsa.

Esquemáticamente, temos:

		Hipótese Correta:	
		H_0	H_1
Decisão:	Aceitar H_0	✓	ERRO TIPO II
	Rejeitar H_0	ERRO TIPO I	✓

Além disso, para cada $\theta \in \Theta$, a **probabilidade de erro tipo I** é dada por $\Pi(\theta) = E_\theta \phi(\mathbf{X})$, se $\theta \in \Theta_0$, e a **probabilidade de erro tipo II**, por $1 - \Pi(\theta)$, se $\theta \in \Theta_1$. Se o teste é não-aleatorizado, então a probabilidade de erro tipo I é dada por $P_\theta(\phi(\mathbf{X}) = 1)$, se $\theta \in \Theta_0$, e a probabilidade de erro tipo II, por $P_\theta(\phi(\mathbf{X}) = 0)$, se $\theta \in \Theta_1$.

Como se observa na Figura 4.5 do Exemplo 4.2.1, é tipicamente impossível tornar ambas as probabilidades de erro tipo I e tipo II arbitrariamente pequenas. Normalmente, quanto menor a probabilidade de Erro Tipo I, maior é a probabilidade de erro tipo II, e vice-versa. Por isso, o que se faz é controlar apenas

uma delas e avaliar posteriormente a outra. Por convenção, a probabilidade controlada é a probabilidade de erro tipo I através do **tamanho do teste** definido por $\sup_{\theta \in \Theta_0} \Pi(\theta)$. Essa quantidade representa o “pior cenário possível relativo ao erro tipo I”.

Exemplo 4.2.1 (Continuação). *Segue de (4.8) que, para $\theta \neq \theta_0$, a probabilidade de erro tipo II é*

$$1 - \Pi(\theta) = P_{\theta}(T \leq \kappa) = \Phi\left(\kappa - \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right) + \Phi\left(\kappa + \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right) - 1,$$

enquanto a probabilidade de erro tipo I é $\Pi(\theta_0) = 2(1 - \Phi(\kappa))$.

Logo, quanto maior o valor crítico κ , mais difícil é rejeitar a H_0 e, portanto, menor é a probabilidade de erro do tipo I (resp., maior para o erro do tipo II). A Figura 4.7 ilustra este fato comparando




Figura 4.7: Probabilidades dos erros tipos I e II (em $\theta = 0, 3$) em função de κ quando $\theta_0 = 0$, $\sigma = 1$ e $n = 100$.

as probabilidades de erro tipo I e de tipo II (no ponto $\theta = 0, 3$). As áreas azuis correspondem às probabilidades $P_{\theta=0}(\bar{X} \geq \kappa/\sqrt{n})$ (erro tipo I), enquanto as áreas vermelhas representam as probabilidades $P_{\theta=0,3}(\bar{X} < \kappa/\sqrt{n})$ (erro tipo II). A figura reforça o padrão descrito acima.

Além disso, analisando em termos do tamanho do teste que, neste caso, é $\Pi(0) = 2\{1 - \Phi(\kappa)\}$, observamos um comportamento consistente com a discussão anterior. Se $\kappa \rightarrow \infty$, então o tamanho do teste se

aproxima de zero: se nunca rejeitamos H_0 , não cometemos o erro do tipo I! Por outro lado, se $\kappa \rightarrow 0$, o tamanho do teste se aproxima de um: se sempre rejeitamos H_0 , então obrigatoriamente cometemos o erro do tipo I quando H_0 é verdadeira. A Figura 4.8 ilustra o comportamento da probabilidade de erro do tipo I neste exemplo em função de κ (curva azul). A curva vermelha tracejada corresponde a $1 - \Pi(0)$ e fornece uma medida conservadora para o erro do tipo II, isto é, o supremo das probabilidades de **não rejeição** de H_0 quando $\theta \in \Theta_1$. Novamente, evidencia-se o comportamento antagônico das probabilidades dos erros




Figura 4.8: Tamanho do teste em função de κ , para $\theta_0 = 0$, $\sigma = 1$ e $n = 100$, no Exemplo 4.2.1.

tipos I e II quando modificamos o valor crítico.

Exemplo 4.3.2. Suponha novamente $H_0 : \theta \leq \theta_0$ vs. $H_1 : \theta > \theta_0$ para uma população Normal com variância conhecida. Dados $X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \mathcal{N}(\theta, \sigma^2)$, então $T = \sqrt{n}(\bar{X} - \theta_0)/\sigma$, em conjunto com a região crítica $\mathcal{R} = \{\mathbf{x} \in \mathbb{R}^n : T(\mathbf{x}) > \kappa\}$, caracteriza um teste não-viciado cuja função poder é

$$\Pi(\theta) = P_\theta(T > \kappa) = 1 - \Phi\left(\kappa - \frac{\theta - \theta_0}{\sigma/\sqrt{n}}\right).$$

Como $\Pi(\cdot)$ é estritamente decrescente em θ , concluímos que o tamanho do teste é

$$\sup_{\theta \leq \theta_0} \Pi(\theta) = \Pi(\theta_0) = 1 - \Phi(\kappa). \quad (4.10)$$

E, como $1 - \Pi(\theta)$ é estritamente decrescente em θ ,

$$\sup_{\theta > \theta_0} (1 - \Pi(\theta)) = 1 - \Pi(\theta_0) = \Phi(\kappa). \quad (4.11)$$

Essas medidas refletem os piores cenários possíveis relativamente aos erros tipos I e II. A figura 4.9 ilustra o comportamento de (4.10) e (4.11) em função de κ .




Figura 4.9: Erros tipos I e II (em $\theta = 0, 3$) em função de κ quando $\theta_0 = 0$, $\sigma = 1$ e $n = 100$ no exemplo 4.3.2.

O teste ϕ , como o p-valor, busca sintetizar a quantidade de evidência contra H_0 em $\mathbf{X}$. Logo, dada uma estatística suficiente $\mathbf{S}$ para θ , devemos poder testar H_0 com base apenas em $\mathbf{S}$, visto que estatísticas suficientes preservam toda a informação sobre o mecanismo gerador de dados contida na amostra.

TEOREMA 4.3.1. *Sejam $X_1, \dots, X_n \sim P_\theta$, com $\theta \in \Theta$, e $\mathbf{S} = \mathbf{S}(\mathbf{X})$ uma estatística suficiente para θ . Então, para qualquer teste $\phi = \phi(\mathbf{X})$ com função poder Π , existe um teste $\tilde{\phi} = \tilde{\phi}(\mathbf{S})$ com função poder $\tilde{\Pi}$ tal que $\tilde{\Pi} \equiv \Pi$. Como consequência, para qualquer $H_0 : \theta \in \Theta_0$, os testes possuem o mesmo tamanho.*

Prova. Seja $\mathbf{S}$ suficiente para θ e tome a estatística $\tilde{\phi} = E(\phi | \mathbf{S})$. Como $\phi(\mathbf{x}) \in [0, 1]$, para todo $\mathbf{x} \in \mathcal{X}_n$, temos $\tilde{\phi} : \mathcal{S} \rightarrow [0, 1]$ (em que $\mathcal{S}$ denota o espaço amostral de $\mathbf{S}$), de modo que $\tilde{\phi}$ também é um teste. Por fim, segue da Lei das Esperanças Iteradas que $\Pi(\theta) = E_\theta \phi = E_\theta E(\phi | \mathbf{S}) = E_\theta \tilde{\phi} = \tilde{\Pi}(\theta)$, para todo $\theta \in \Theta$. Em particular, $\sup_{\theta \in \Theta_0} \Pi(\theta) = \sup_{\theta \in \Theta_0} \tilde{\Pi}(\theta)$, o que demonstra a afirmação final do teorema. $\square$

Em outras palavras, dado um teste qualquer, o teorema garante que sempre podemos obter um segundo teste no mínimo tão bom quanto o primeiro, porém, baseado unicamente numa estatística suficiente. O que o teorema não diz é que este é o melhor teste que podemos obter com base na mesma estatística suficiente!

Nos dois exemplos acima, fixamos κ para determinar o tamanho do teste. Porém, se queremos controlar o erro tipo I é mais natural inverter essa lógica e primeiro estabelecer a probabilidade máxima de erro tipo

I que estamos dispostos a admitir para, em seguida, determinar κ . Ou seja, fixamos $0 < \alpha < 1$ e buscamos minimizar o erro tipo II sujeitos à restrição

$$\sup_{\theta \in \Theta_0} \Pi(\theta) \leq \alpha.$$

A quantidade α se chama **nível de significância** do teste. Em muitos casos, o problema acima é resolvido substituindo a desigualdade acima por uma igualdade, de modo que o nível de significância e o tamanho do teste coincidam. A distinção é necessária, pois, não se pode garantir que, fixado α , é possível construir um teste cujo tamanho coincida com o nível de significância.

Exemplo 4.2.1 (Continuação). Fixado $0 < \alpha < 1$, queremos $\kappa > 0$ tal que

$$\alpha = \Pi(\theta_0) = 2(1 - \Phi(\kappa)).$$

Isso implica $\kappa = z_{1-\alpha/2}$, de modo que a região crítica correspondente é $\mathcal{R} = [T > z_{1-\alpha/2}]$.

Exemplo 4.3.2 (Continuação). De (4.10), fixado $0 < \alpha < 1$, queremos $\kappa > 0$ tal que

$$\alpha = 1 - \Phi(\kappa),$$

implicando $\kappa = z_{1-\alpha}$. A região crítica correspondente é dada por

$$\mathcal{R} = \left\{ \mathbf{x} \in \mathcal{X}_n : \bar{X} > \theta_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha} \right\}.$$

Nos exemplos acima, o nível de significância coincide com o tamanho do teste. Isso acontece porque a distribuição acumulada da estatística teste é estritamente crescente. Veremos agora um caso em que o nível de significância e o tamanho do teste não coincidem.

Exemplo 4.3.3. Sejam $X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \text{Poisson}(\theta)$. Para testar $H_0 : \theta = 1$ vs. $H_1 : \theta > 1$, tome $T = \sum_{i=1}^n X_i$ e $\mathcal{R} = \{\mathbf{x} \in \mathbb{N}^n : T(\mathbf{x}) > \kappa\}$, com $\kappa \in \mathbb{N}$. Segue disso que $T \sim \text{Poisson}(n\theta)$. Logo,

$$\Pi(\theta) = \sum_{t=\kappa+1}^{\infty} \frac{e^{-n\theta} (n\theta)^t}{t!}, \quad (4.12)$$

de modo que, fixado α , não existe $\kappa \in \mathbb{N}$ satisfazendo $\Pi(1) = \alpha$, pois $\Pi(1)$ é descontínua com relação κ . A figura 4.10 ilustra isso no caso em que $n = 50$ e $\alpha = 5\%$. Nota-se ali que

$$\sum_{t=62}^{\infty} \frac{e^{-50} 50^t}{t!} < 0,05 < \sum_{t=61}^{\infty} \frac{e^{-50} 50^t}{t!},$$

o que sugere $\kappa = 62$. Porém, neste caso, o tamanho do teste é $P_1(T > 62) = 4,24\%$ e, portanto, diferente de $\alpha = 5\%$. De forma mais geral, no contexto deste exemplo, escolheríamos κ modo que

$$\sum_{t=\kappa}^{\infty} \frac{e^{-n} n^t}{t!} \leq \alpha < \sum_{t=\kappa-1}^{\infty} \frac{e^{-n} n^t}{t!}.$$




Figura 4.10: Função poder (4.12) calculada em $\theta = 1$ para diferentes valores de κ quando $n = 50$. A linha tracejada representa o nível de significância $\alpha = 5\%$.

4.3.4 Testes Assintóticos

A determinação da distribuição do teste nem sempre é trivial. Uma forma de contornar este problema consiste na aproximação assintótica da distribuição de interesse. Porém, em se tratando de uma aproximação, o tamanho do teste também deve ser aproximado. Mais precisamente, se (ϕ_n) é uma sequência de testes, dizemos que α é um **nível de significância assintótico** de ϕ_n se

$$\limsup_{n \rightarrow \infty} \Pi_n(\theta) \leq \alpha, \quad \forall \theta \in \Theta_0,$$

em que $\Pi_n(\theta) = E_\theta \phi_n(\mathbf{X})$. Analogamente, dizemos que

$$\lim_{n \rightarrow \infty} \sup_{\theta \in \Theta_0} \Pi_n(\theta)$$

é o **tamanho assintótico** de ϕ_n .

Exemplo 4.3.4. Sejam $X_1, \dots, X_n$ i.i.d. com média μ e variância $\sigma^2 < \infty$ desconhecidos. Para testar $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$, tome a estatística teste

$$T_n = \frac{\bar{X}_n - \mu_0}{S_n / \sqrt{n}}, \quad (4.13)$$

associada à região crítica $[T_n > z_{1-\alpha}]$. Neste caso, $\phi_n(\mathbf{X}_n) = \mathbb{1}(T_n > z_{1-\alpha})$. Portanto, sob H_0 e aplicando o TLC em conjunto com o teorema de Slutsky, obtemos

$$\begin{aligned} \Pi_n(\mu, \sigma^2) &= P_{\mu, \sigma^2}(T_n > z_{1-\alpha}) = P_{\mu, \sigma^2} \left(\frac{\bar{X}_n - \mu}{S_n / \sqrt{n}} + \frac{\mu - \mu_0}{S_n / \sqrt{n}} > z_{1-\alpha} \right) \\ &\leq P_{\mu, \sigma^2} \left(\frac{\bar{X}_n - \mu}{S_n / \sqrt{n}} > z_{1-\alpha} \right) \\ &\rightarrow 1 - \Phi(z_{1-\alpha}) = \alpha, \end{aligned}$$

quando $n \rightarrow \infty$. Portanto, para todo $\mu \leq \mu_0$ e σ^2 , existe $n = n(\mu, \sigma^2)$ tal que $m \geq n$ implica $\Pi_m(\mu, \sigma^2) \leq \alpha$. Logo,

$$\limsup_{n \rightarrow \infty} \Pi_n(\mu, \sigma^2) = \lim_{n \rightarrow \infty} \sup_{m \geq n} \Pi_m(\mu, \sigma^2) \leq \alpha,$$

para todo $\mu \leq \mu_0$ e $\sigma^2 > 0$. Ou seja, T_n define um teste com nível de significância assintótico α .

Exemplo 4.3.3 (Continuação). Para testar $H_0 : \theta = 1$ vs. $H_1 : \theta > 1$ quando $X_1, \dots, X_n \stackrel{\text{ind}}{\sim} \text{Poisson}(\theta)$, tome a estatística teste $T_n = \sqrt{n}(\bar{X}_n - 1)$ e considere novamente um teste da forma $\phi_n(\mathbf{X}_n) = \mathbb{1}(T_n > z_{1-\alpha})$. Portanto, sob H_0 e aplicando o TLC,

$$\Pi_n(1) = P_{\theta=1}(T_n > z_{1-\alpha}) = P_{\theta=1}(\sqrt{n}(\bar{X}_n - 1) > z_{1-\alpha}) \rightarrow 1 - \Phi(z_{1-\alpha}) = \alpha,$$

quando $n \rightarrow \infty$. Logo, $\limsup_{n \rightarrow \infty} \Pi_n(1) = \lim_{n \rightarrow \infty} \Pi_n(1) = \alpha$. Ou seja, T_n define um teste com nível de significância assintótico α .

Observe que $T_n > z_{1-\alpha}$ se, e somente se, $\sum_{i=1}^n X_i > \sqrt{n}z_{1-\alpha} + n$. Portanto, se $n = 50$ e $\alpha = 5\%$, rejeitamos H_0 se, e somente se, $\sum_{i=1}^n X_i > \sqrt{50} \times z_{0,95} + 50 = 58,72$. Observando a figura 4.10, notamos que um valor crítico igual a 58,72 < 62 implica um teste de tamanho superior a $\alpha = 5\%$. Isso se deve ao fato de que n não é suficientemente grande para garantir uma aproximação mais precisa da Poisson pela Normal. A figura 4.11 mostra que essas quantidades se aproximam uma da outra conforme $n \rightarrow \infty$.




Figura 4.11: Razão entre o valor crítico exato κ e o seu valor correspondente obtido a partir da aproximação pela distribuição Normal.

Testes assintóticos também devem ter um bom desempenho em Θ_1 e, assim como com a significância, esse desempenho deve ser avaliado assintoticamente. Neste sentido, dizemos que a sequência de testes ϕ_n é **consistente** se $\lim_{n \rightarrow \infty} \Pi_n(\theta) = 1$, para todo $\theta \in \Theta_1$. Ou seja, uma sequência de testes é consistente se a probabilidade de erro tipo II converge para zero em toda a região Θ_1 .

Exemplo 4.3.5. Suponha $X_1, \dots, X_n \stackrel{ind}{\sim} \mathcal{N}(\mu, \sigma^2)$, com σ^2 conhecida. Se para testar $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$, usamos $T_n = \sqrt{n}(\bar{X}_n - \mu_0)/\sigma$ com $\mathcal{R} = [T_n > z_{1-\alpha}]$, então

$$\Pi_n(\mu) = 1 - \Phi\left(z_{1-\alpha} - \frac{\mu - \mu_0}{\sigma/\sqrt{n}}\right) \rightarrow 1$$

quando $n \rightarrow \infty$, sob H_1 . Ou seja, a sequência de testes $\phi_n = \mathbb{1}(T_n > z_{1-\alpha})$ é consistente.

Exemplo 4.3.4 (Continuação). Como no exemplo anterior, temos $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$, porém, agora, com distribuição e variância σ^2 desconhecidos. Fixando $\mu > \mu_0$, temos

$$\begin{aligned} \Pi_n(\mu, \sigma^2) &= P_{\mu, \sigma^2} \left(\frac{\bar{X}_n - \mu}{S_n} + \frac{\mu - \mu_0}{S_n} > \frac{z_{1-\alpha}}{\sqrt{n}} \right) \\ &= P_{\mu, \sigma^2} \left(\frac{\bar{X}_n - \mu}{S_n} + \frac{\mu - \mu_0}{S_n} - \frac{\mu - \mu_0}{\sigma^2} > \frac{z_{1-\alpha}}{\sqrt{n}} - \frac{\mu - \mu_0}{\sigma^2} \right). \end{aligned}$$

Por outro lado,

$$V_n = \frac{\bar{X}_n - \mu}{S_n} \xrightarrow{P} 0$$

e

$$W_n = \frac{\mu - \mu_0}{S_n} - \frac{\mu - \mu_0}{\sigma^2} \xrightarrow{P} 0,$$

de modo que $V_n + W_n \xrightarrow{P} 0$. Como, para n suficientemente grande,

$$\frac{z_{1-\alpha}}{\sqrt{n}} < \frac{\mu - \mu_0}{2\sigma^2} \equiv c,$$

temos

$$\Pi_n(\mu, \sigma^2) \geq P_{\mu, \sigma^2}(V_n + W_n > -c) \geq P_{\mu, \sigma^2}(|V_n + W_n| \leq c) \xrightarrow{P} 1,$$

para todo $\mu > \mu_0$ e $\sigma^2 > 0$. Em outras palavras, mesmo sem as premissas de normalidade e variância conhecida, a sequência de testes induzida pelas estatísticas (4.13) e regiões críticas $[T_n > z_{1-\alpha}]$ é consistente.